UFR de mathématique et d'informatique
Université de Strasbourg

UFR de Mathématiques et Informatique
Master 1 Informatique
Année universitaire 2025/2026

High Dimensionality Visualization

Étudiants : **SIMON Elouan**
ATES Ahmet

Encadrant : Mazellier Jean-Paul

Module : Deep Learning

Date : 21 janvier 2026

Résumé du projet

Les réseaux de neurones profonds opèrent via des transformations géométriques complexes en très haute dimension, rendant leur fonctionnement interne difficilement interprétable. Ce projet explore la visualisation de ces espaces latents grâce à l'algorithme de réduction de dimension UMAP. En analysant la topologie des projections sur des jeux de données variés, l'objectif est de comprendre la dynamique d'apprentissage, l'impact du pré-entraînement et la capacité du modèle à structurer l'information pour séparer les classes.

Table des matières

1 Introduction **2**

2 Revue de l'article *High Dimensionality Visualization* **3**

3 Méthodologie **4**

3.1 Expérience 0 4

3.2 Expérience 1 4

3.3 Expérience 2 4

3.4 Expérience 3 5

3.5 Expérience 4 5

3.6 Expérience 5 5

4 Résultats d'expériences **6**

4.1 Expérience 0 6

4.2 Expérience 1 7

4.3 Expérience 2 10

4.4 Expérience 3 11

5 Discussion et conclusion **12**

1 Introduction

Les modèles d'apprentissage profond manipulent des données et des représentations internes de très grande dimension. Ces espaces de représentation, bien que essentiels au bon fonctionnement des réseaux de neurones, sont difficiles à interpréter directement, car ils dépassent largement les dimensions auxquelles nous sommes habitués (2D ou 3D). Il devient alors complexe de comprendre comment les données sont progressivement transformées au fil des couches d'un réseau.

Afin de mieux analyser et interpréter ces transformations, il est possible d'utiliser des méthodes de réduction de dimensionnalité. Ces méthodes permettent de projeter des données de grande dimension dans un espace de plus faible dimension tout en conservant, autant que possible, leur structure essentielle. Parmi les approches les plus utilisées figurent la PCA, t-SNE et UMAP. Elles sont largement employées pour visualiser des données, analyser des espaces latents et mieux comprendre le comportement des réseaux de neurones.

L'objectif de ce projet est d'explorer l'utilisation de ces méthodes de visualisation, et plus particulièrement UMAP, afin d'analyser les projections réalisées par des réseaux de neurones au cours de l'apprentissage. À travers plusieurs expériences, nous cherchons à visualiser l'évolution des représentations internes, à comparer différentes architectures et configurations d'entraînement, et à étudier le comportement des réseaux face à des données de test ou hors domaine.

Ce travail s'appuie notamment sur l'étude de l'article de van der Maaten et Hinton sur la méthode t-SNE, qui constitue une référence majeure dans le domaine de la visualisation de données de grande dimension. Bien que cet article se concentre sur t-SNE, les expériences menées dans ce projet utilisent principalement la méthode UMAP, mieux adaptée en termes de performance et de passage à l'échelle.

2 Revue de l'article *High Dimensionality Visualization*

L'article de van der Maaten et Hinton propose la méthode *t-Distributed Stochastic Neighbor Embedding* (t-SNE), destinée à la visualisation de données de grande dimension dans des espaces de faible dimension (principalement 2D ou 3D). La problématique centrale abordée par les auteurs est la difficulté à représenter fidèlement la structure des données haute dimension, en particulier lorsque celles-ci reposent sur des variétés non linéaires et présentent des structures locales complexes, comme c'est le cas pour des images ou des données textuelles

Les méthodes classiques de réduction de dimension, telles que la PCA ou le MDS, privilégient la préservation des distances globales mais échouent souvent à conserver la structure locale des données. À l'inverse, des approches non linéaires comme Isomap ou LLE tentent de préserver les voisinages locaux, mais souffrent de limitations importantes, notamment en présence de sous-variétés multiples ou de graphes de voisinage mal connectés. Les auteurs identifient en particulier le *crowding problem*, qui correspond à l'incapacité des méthodes existantes à représenter simultanément des relations locales fines et une organisation globale lisible dans un espace de faible dimension.

L'approche proposée par t-SNE repose sur une modélisation probabiliste des similarités entre points. Dans l'espace d'origine, les distances sont converties en probabilités conditionnelles à l'aide de noyau Référencesx gaussiens, dont la largeur est ajustée localement via la notion de *perplexité*. Dans l'espace projeté, t-SNE utilise une loi de Student à queue lourde pour modéliser les similarités, ce qui permet de réduire le phénomène d'agglutination des points et de favoriser la séparation naturelle des groupes. L'optimisation repose sur la minimisation de la divergence de Kullback–Leibler entre les distributions de similarité haute et basse dimension, via une descente de gradient non convexe.

Les résultats expérimentaux présentés dans l'article montrent que t-SNE surpasse nettement des méthodes concurrentes telles que Sammon Mapping, Isomap ou LLE sur plusieurs jeux de données de référence (MNIST, Olivetti Faces, COIL-20). Les visualisations obtenues révèlent des clusters bien séparés et mettent en évidence des variations internes cohérentes au sein des classes, confirmant la capacité de t-SNE à préserver la structure locale tout en offrant une organisation globale interprétable.

Bien que cet article se concentre sur la méthode t-SNE, notre travail expérimental repose sur l'utilisation de la méthode *UMAP* (*Uniform Manifold Approximation and Projection*). UMAP s'inscrit dans la continuité conceptuelle de t-SNE en cherchant également à préserver les voisinages locaux, mais propose une formulation mathématique fondée sur la théorie des variétés et des ensembles flous. Elle présente l'avantage d'une meilleure scalabilité, d'une optimisation plus rapide et d'une meilleure préservation de certaines structures globales. Ainsi, l'article de van der Maaten et Hinton constitue une référence fondamentale pour comprendre les enjeux théoriques et pratiques de la visualisation de données de grande dimension, tout en fournissant le cadre conceptuel dans lequel s'inscrit l'utilisation d'UMAP dans nos expériences.

3 Méthodologie

3.1 Expérience 0

UMAP est un algorithme de réduction de dimensionnalité non linéaire permettant de projeter des données de grande dimension dans un espace de dimension plus faible, généralement en deux ou trois dimensions, tout en préservant au mieux leur structure intrinsèque. UMAP, acronyme de *Uniform Manifold Approximation and Projection*, s'appuie sur les principes de l'apprentissage des variétés ainsi que sur des concepts issus de l'analyse topologique afin de modéliser les relations locales entre les données et d'en déduire une représentation globale cohérente dans l'espace projeté [1].

Pour cette expérience, nous allons créer une projection UMAP pour les datasets MNIST et ImageNet 1K (limitè aux 10 premières classes. Pour ce faire

3.2 Expérience 1

Le jeu de données Spiral 3 a été utilisé afin d'entraîner un réseau de neurones sur un problème de classification non linéaire. Un réseau entièrement connecté a été mis en place, et plusieurs hyperparamètres ont été ajustés, tels que le taux d'apprentissage, la régularisation (weight decay) et le nombre de couches cachées, afin d'obtenir une convergence correcte de l'entraînement et des résultats satisfaisants en classification.

Une fois ces hyperparamètres fixés, les projections des données ont été visualisées à différentes couches du réseau. Pour une couche donnée, les activations des neurones sont extraites et représentées dans un espace bidimensionnel, en conservant le code couleur associé aux classes. Cette visualisation permet d'observer comment les données sont progressivement transformées par le réseau au cours de l'entraînement.

Les couches cachées sont limitées à deux neurones afin de permettre une visualisation directe des représentations internes, sans utiliser de méthode supplémentaire de réduction de dimensionnalité. Ce choix facilite l'interprétation du comportement du réseau et la compréhension de la construction des frontières de décision.

3.3 Expérience 2

Dans cette expérience, nous comparons l'entraînement d'un classificateur ResNet18 sur le jeu de données MNIST dans deux configurations : une première version entraînée à partir de poids initiaux aléatoires, et une seconde version utilisant des poids pré-entraînés sur ImageNet. Pour chacune de ces deux configurations, nous observons la répartition des projections des données d'entrée juste avant la couche de dépliage (flatten), à l'aide de la méthode de visualisation UMAP.

1. https ://www.datacamp.com/fr/tutorial/understanding-umap-guide-to-dimensionality-reduction

3.4 Expérience 3

Dans cette expérience, nous utilisons notre script d'entraînement d'un ResNet50 sur le jeu de données ImageNet 1K, en nous limitant à un sous-ensemble contenant uniquement les 10 premières classes. Ce sous-ensemble est utilisé de la même manière pour les ensembles d'entraînement, de validation et de test.

Nous reproduisons ensuite le même processus que dans l'Expérience 1, mais appliqué à ce nouveau problème, plus complexe que les jeux de données précédents. L'apprentissage du réseau est suivi au cours des époques à l'aide des courbes de loss et d'accuracy sur les jeux d'entraînement et de validation.

En parallèle, nous visualisons les représentations internes du réseau à différentes couches à l'aide de projections UMAP, en conservant le code couleur des classes. Ces visualisations permettent d'observer comment les données sont progressivement transformées par le réseau et comment les classes deviennent de mieux en mieux séparées au fur et à mesure de l'entraînement.

3.5 Expérience 4

Dans cette expérience, nous réutilisons les réseaux de neurones entraînés lors des expériences 1 et 2, en sélectionnant uniquement ceux présentant des performances de classification satisfaisantes. Ces modèles sont ensuite appliqués aux images du jeu de test, afin d'analyser la généralisation des représentations apprises.

Les projections UMAP sont entraînées à partir des représentations extraites sur le jeu d'entraînement, en utilisant un sous-échantillon de ce dernier (par exemple 5 000 images) afin de limiter le temps de calcul. Différentes tailles de sous-échantillonnage sont testées, et celle offrant un bon compromis entre qualité de représentation et coût de calcul est conservée.

Une fois la projection UMAP entraînée, les données du jeu d'entraînement et du jeu de test sont projetées dans le même espace. Les résultats obtenus sont ensuite comparés afin d'observer les différences éventuelles entre les distributions des données de train et de test. Cette comparaison permet d'évaluer si les représentations apprises par les réseaux restent cohérentes sur des données jamais vues, et donc d'analyser la capacité de généralisation des modèles.

3.6 Expérience 5

Dans cette expérience, nous réutilisons les réseaux entraînés lors des expériences 1 et 2, en ne conservant que ceux présentant des performances satisfaisantes. Ces modèles sont cette fois appliqués à des données hors domaine, c'est-à-dire provenant de jeux de données différents de ceux utilisés pour l'entraînement.

Pour le réseau entraîné sur MNIST, nous utilisons le jeu de données KMNIST, qui contient des caractères japonais manuscrits. Pour le réseau entraîné sur ImageNet (10

classes), nous utilisons le jeu de données EuroSat, composé d'images satellites. Les projections UMAP sont entraînées uniquement à partir des données du jeu d'entraînement d'origine, puis les données hors domaine sont projetées dans le même espace.

4 Résultats d'expériences

4.1 Expérience 0

3. Observations et Résultats

Cas MNIST : La projection UMAP révèle une structure en *clusters* distincts. Bien que certaines frontières soient floues, les classes se regroupent naturellement.

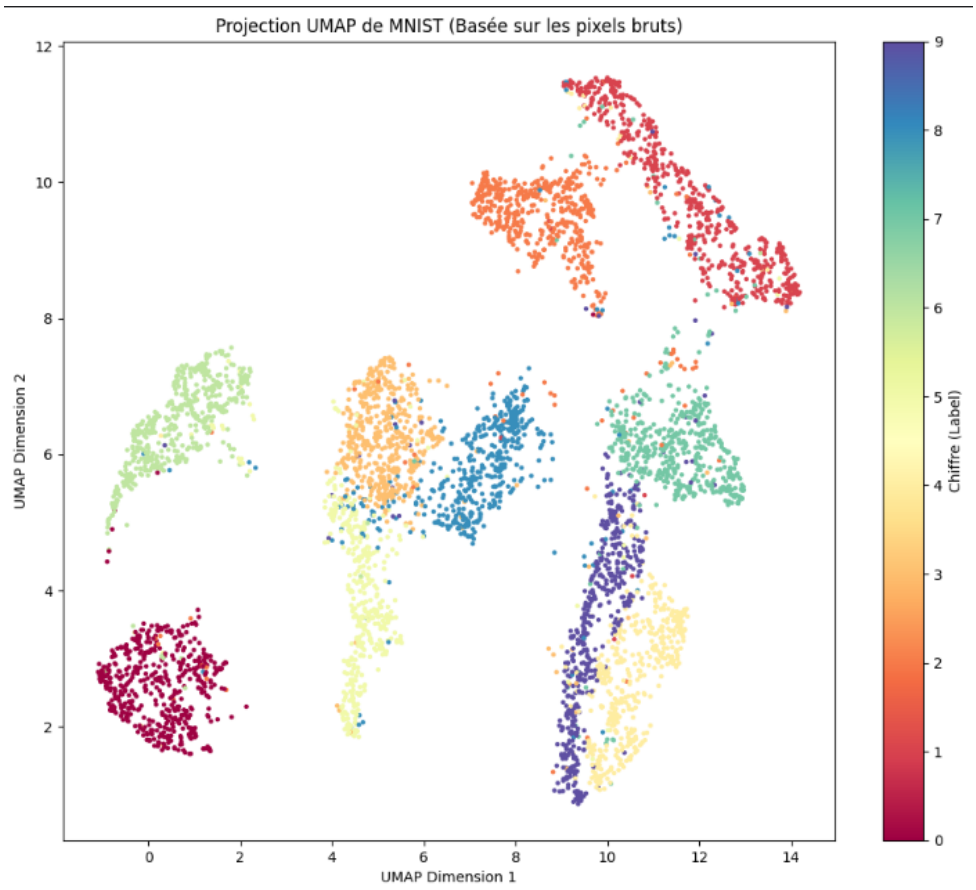


FIGURE 1 – Projection UMAP des pixels de MNIST. On observe une séparation naturelle des classes.

Cas ImageNet (10 classes) : Contrairement à MNIST, la projection des données brutes d'ImageNet ne montre aucune séparation claire. Le résultat s'apparente à un nuage de points où les différentes catégories sont fortement melangées.

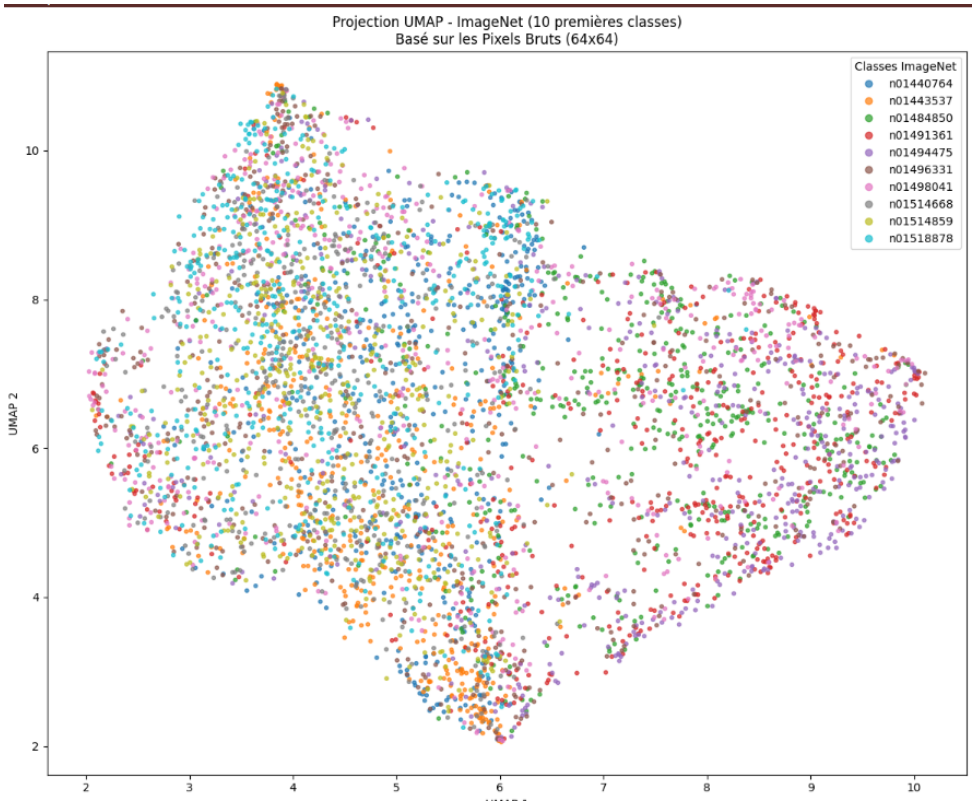


FIGURE 2 – Projection UMAP des pixels bruts d'ImageNet (10 classes). Les classes sont mélangées, montrant les limites de l'espace des pixels.

4.2 Expérience 1

Comparaison de l'impact de la profondeur (Largeur fixée à 2 neurones)

2 couches cachés : Échec. La frontière de décision reste est très flou . Le réseau manque de capacité topologique : il ne possède pas assez de transformations successives pour choisir le bon espace.

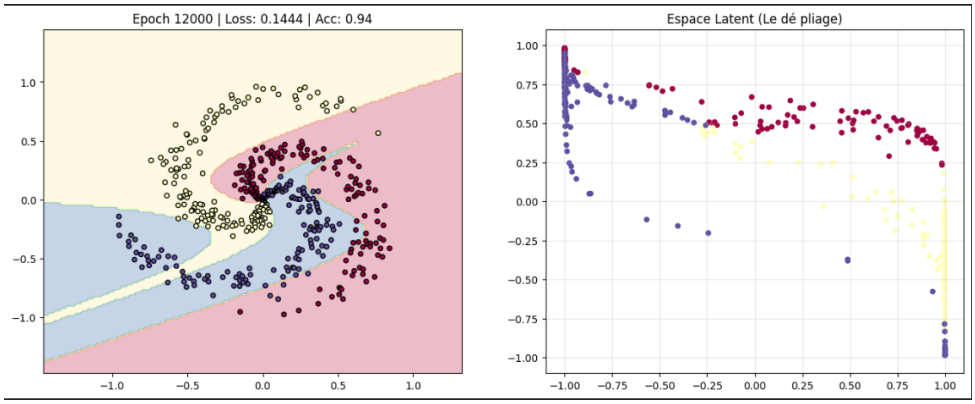


FIGURE 3 – Projection UMAP des pixels bruts d'ImageNet (3 classes). Les classes sont mélangées, montrant les limites de l'espace des pixels.

6 couches cachés : Succès. Le modèle converge rapidement vers une spirale fluide.

C'est le point d'équilibre idéal : la profondeur est suffisante pour résoudre la complexité du problème sans introduire de difficultés d'optimisation.

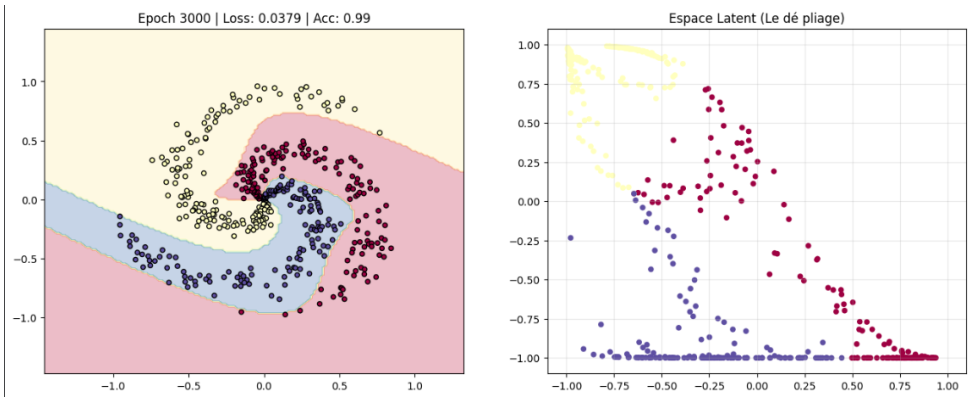


FIGURE 4 – Projection UMAP des pixels bruts d'ImageNet (3 classes).

10 couches cachés : Succès mitigé. Bien que capable de résoudre le problème, l'entraînement est instable. Le réseau souffre du vanishing gradient

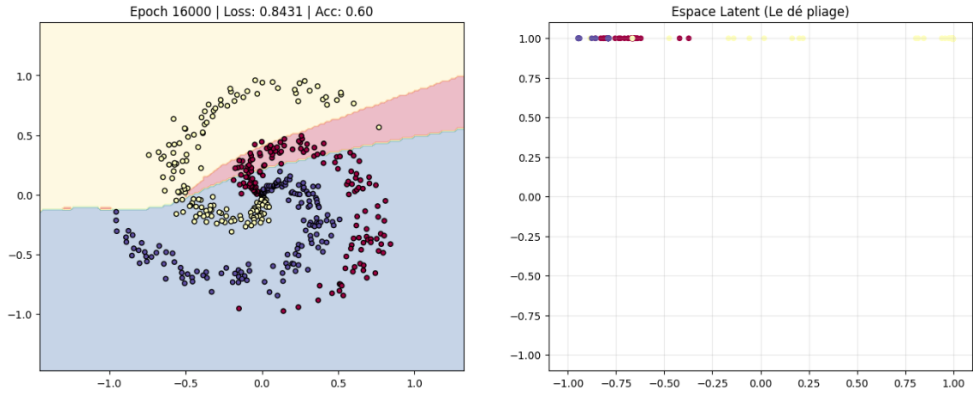


FIGURE 5 – Projection UMAP des pixels bruts d'ImageNet (3 classes).

weigth decay nul : Sur-apprentissage (Overfitting). L'absence de régularisation laisse les poids exploser, rendant le réseau hypersensible au bruit des données. Les frontières de décision deviennent hachées et irrégulières au lieu d'être fluides.

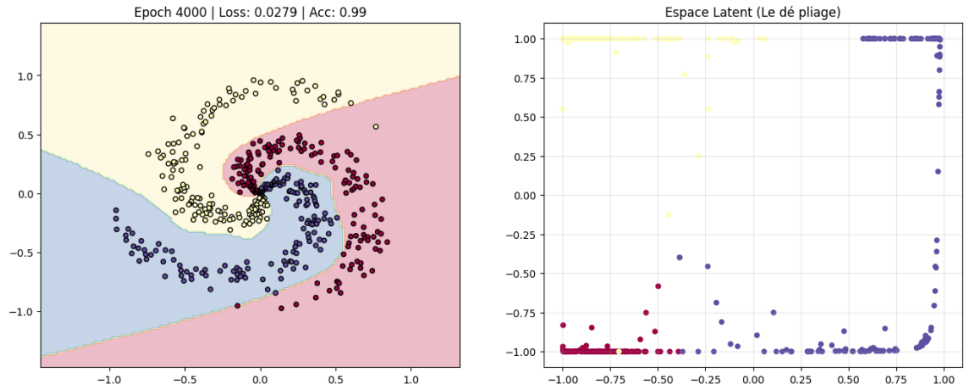


FIGURE 6 – Projection UMAP des pixels bruts d'ImageNet (3 classes).

weigth decay lourd :

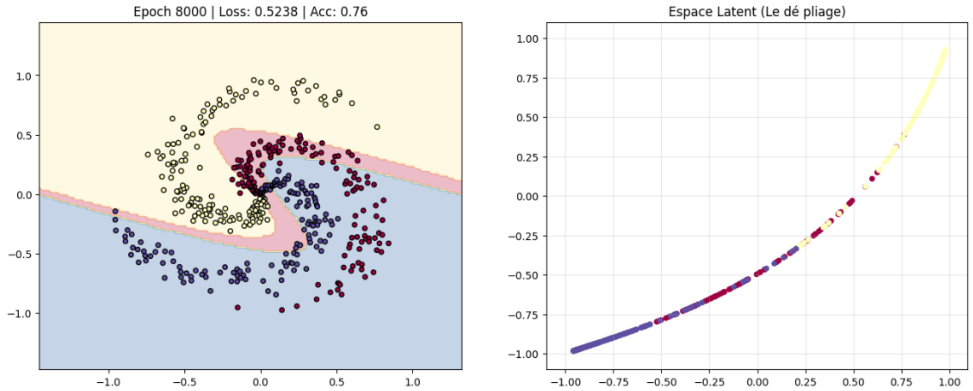
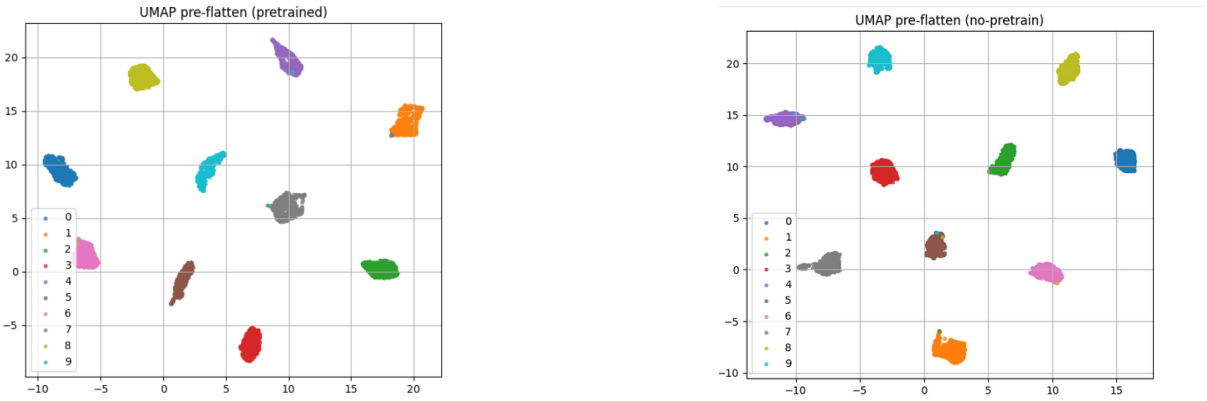


FIGURE 7 – Projection UMAP des pixels bruts d'ImageNet (3 classes)

Sous-apprentissage : Un weight decay trop important agit en empêchant les poids de grandir suffisamment pour créer les torsions nécessaires. Le modèle est trop rigide pour suivre la spirale : les frontières sont excessivement lisses et l'espace latent se retrouve comprimé sur une trajectoire simpliste (quasi 1D), échouant à séparer complètement les classes.

4.3 Expérience 2



Avec pré-entrainement Sans pré-entrainement

FIGURE 8 – Visualisation UMAP des représentations extraites de ResNet18

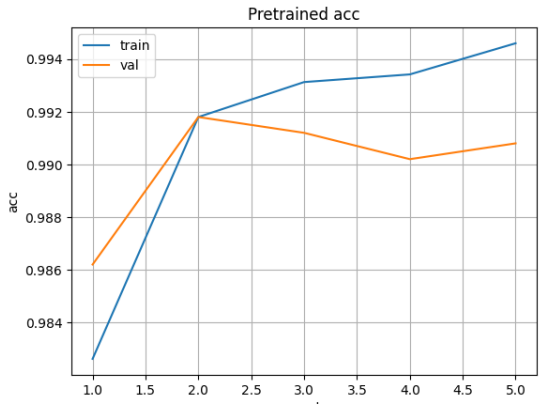


FIGURE 9 – Les courbes d'apprentissage du modele pré-entrainé

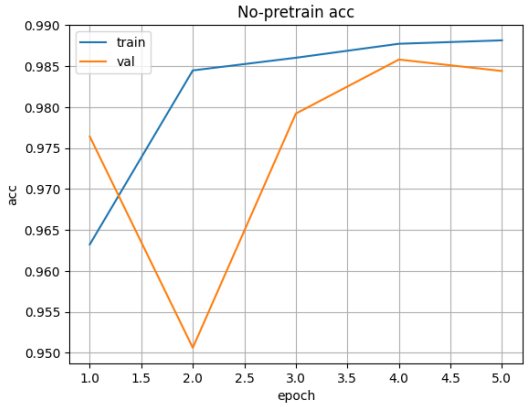


FIGURE 10 – Les courbes du modele sans pré-entrainemet

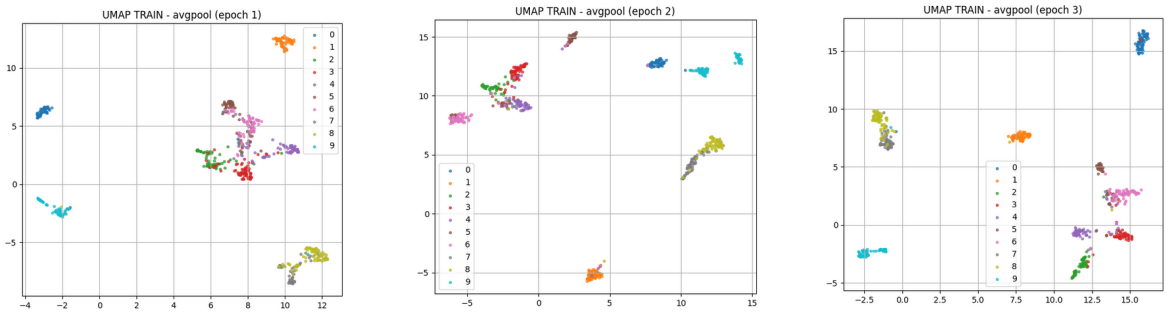
Dans l'expérience 2, la comparaison entre un réseau ResNet18 entraîné à partir de poids aléatoires et un réseau pré-entraîné sur ImageNet met en évidence l'impact du pré-

entraînement. Les courbes d'apprentissage montrent une convergence rapide dans les deux cas, et les projections UMAP révèlent des amas de classes visuellement similaires, sans séparation nettement supérieure pour l'un ou l'autre modèle.

4.4 Expérience 3

Dans cette expérience, nous avons entraîné un réseau de neurones convolutionnel de type *ResNet50* sur un sous-ensemble du jeu de données *ImageNet 1K*, limité aux dix premières classes. Le jeu de données a été séparé en un ensemble d'entraînement et un ensemble de validation, et l'apprentissage a été réalisé à partir de poids pré-entraînés sur ImageNet.

Prennons l'ensemble d'entrainement d'AveragePool pour trois epochs d'entrainements :



Époque 1 Époque 2 Époque 3

FIGURE 11 – Visualisation UMAP des représentations extraites de la couche *avgpool* du ResNet50 au cours de l'entraînement sur ImageNet-10.

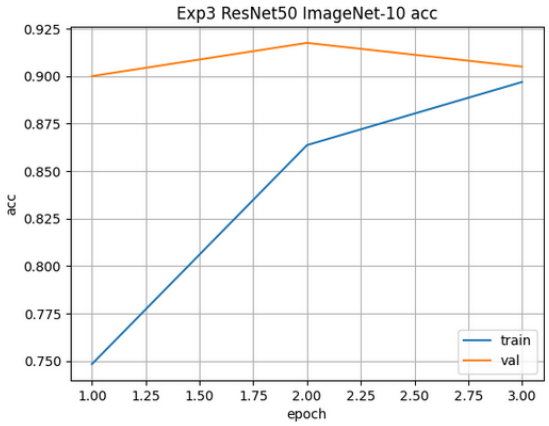


FIGURE 12 – Courbe d'apprentissage du resNet 50

Nous pouvons observer que, au fur et à mesure de l'entraînement, les projections UMAP deviennent progressivement mieux séparées. Les différentes classes forment des amas de plus en plus compacts et éloignés les uns des autres, ce qui reflète l'amélioration des performances du modèle lors de l'apprentissage.

5 Discussion et conclusion

Dans ce projet, nous avons étudié la visualisation des représentations internes de réseaux de neurones profonds à l'aide de méthodes de réduction de dimensionnalité, en particulier UMAP. L'objectif principal était de mieux comprendre comment les données sont progressivement transformées au sein des réseaux et comment ces transformations influencent les performances de classification.

À travers l'expérience 0, nous avons mis en évidence les limites de l'espace des pixels bruts. Si des jeux de données simples comme MNIST présentent déjà une structure exploitable dans cet espace, ce n'est pas le cas pour des données plus complexes telles qu'ImageNet, pour lesquelles les classes sont fortement entremêlées. Cela montre la nécessité d'utiliser des représentations apprises par des réseaux profonds.

L'expérience 1, menée sur un jeu de données artificiel, a permis d'observer de manière intuitive la construction progressive des frontières de décision et l'évolution des représentations internes au fil de l'entraînement. Le choix de couches cachées à deux neurones a facilité l'interprétation directe de ces transformations.

Dans l'expérience 2, la comparaison entre un réseau ResNet18 entraîné à partir de poids aléatoires et un réseau pré-entraîné sur ImageNet met en évidence l'intérêt du pré-entraînement. Les courbes d'apprentissage montrent une convergence rapide dans les deux cas, et les projections UMAP révèlent des amas de classes visuellement comparables, sans séparation nettement supérieure pour l'un ou l'autre modèle.

L'expérience 3 a étendu cette analyse à un problème plus complexe, en utilisant un ResNet50 entraîné sur un sous-ensemble d'ImageNet. Les visualisations UMAP des représentations extraites de la couche *avgpool* montrent que, au fil des époques, les classes deviennent progressivement mieux séparées et plus compactes. Cette structuration de l'espace latent est cohérente avec l'amélioration des performances observée sur les courbes d'apprentissage.

Dans l'expérience 4, l'objectif était de comparer les projections UMAP des données d'entraînement et de test à l'aide d'un même modèle de projection entraîné sur le jeu d'entraînement. Ce type d'analyse permet de vérifier que les représentations apprises restent cohérentes sur des données jamais vues. On s'attend généralement à observer une structure similaire entre les deux ensembles, avec éventuellement une dispersion légèrement plus importante pour les données de test, traduisant les effets de la généralisation.

Enfin, l'expérience 5 visait à analyser le comportement des réseaux face à des données hors domaine. Dans ce cas, les projections UMAP sont entraînées sur les données d'origine puis appliquées à des jeux de données différents, comme KMNIST ou EuroSat. On s'attend alors à ce que les données hors domaine apparaissent décalées ou moins structurées dans l'espace latent, voire regroupées dans des régions distinctes de celles des données d'entraînement. Ces observations permettent d'illustrer les limites de généralisation des modèles et d'analyser leur sensibilité au changement de distribution des données.

En conclusion, ce projet montre que les méthodes de visualisation comme UMAP constituent des outils précieux pour analyser et interpréter le fonctionnement interne des réseaux de neurones profonds. Elles permettent de relier de manière qualitative les

performances de classification à la structuration des espaces latents, et offrent un éclairage complémentaire aux métriques quantitatives classiques.